

Tugas Proyek Dua Minggu

Analisis Kualitas Air pada Smart Aquaculture

Durasi	14 hari
Bentuk kerja	Kelompok, 3–4 mahasiswa
Dataset	<code>smart_aqua_synthetic_water_quality.csv</code>
Unit observasi	Satu kolam pada satu waktu pengukuran 30 menit

1 Skenario Studi Kasus

Sebuah unit budidaya nila intensif mengelola delapan kolam air tawar. Setiap kolam dilengkapi sensor yang mencatat suhu, pH, oksigen terlarut, amonia, nitrit, dan kekeruhan setiap 30 menit. Sistem juga mencatat pemberian pakan, keadaan aerator, curah hujan, pertukaran air, estimasi biomassa, dan tanda stres ikan.

Selama beberapa minggu, pengelola melihat bahwa rata-rata kualitas air tampak memadai. Namun, tanda stres ikan masih muncul pada waktu dan kolam tertentu. Pengelola belum mengetahui apakah kejadian tersebut berkaitan dengan siklus harian, pertumbuhan biomassa, pemberian pakan, hujan, gangguan aerator, atau kesalahan sensor.

Pengelola ingin menggunakan data untuk menjawab tiga tingkat pertanyaan:

1. **Descriptive analytics:** apa yang terjadi pada kualitas air selama periode pengamatan?
2. **Diagnostic analytics:** kondisi apa yang berkaitan dengan munculnya kualitas air berisiko dan mengapa pola tersebut terlihat?
3. **Predictive analytics:** dapatkah kondisi berisiko diprediksi tiga jam sebelum terjadi?

Masalah Keputusan

Manajer harus memutuskan apakah jadwal aerator, pemeriksaan perangkat, pemberian pakan, atau pertukaran air perlu disesuaikan pada kolam dan waktu tertentu. Tim analitik juga diminta membuat model *early warning* yang memperkirakan risiko kualitas air dalam tiga jam berikutnya.

Data bersifat sintetis, terdiri atas 23.040 observasi dari delapan kolam selama 60 hari. Dataset sengaja memuat struktur waktu, perbedaan antar-kolam, kejadian gangguan operasional, *missing values*, *spike*, *flatline*, dan *sensor drift*. Mahasiswa harus memperlakukan masalah kualitas data sebagai bagian dari analisis, bukan sekadar menghapus seluruh nilai yang tidak biasa.

2 Tujuan Pembelajaran

Setelah menyelesaikan proyek, mahasiswa mampu:

1. membedakan tujuan dan keluaran descriptive, diagnostic, dan predictive analytics;
2. melakukan audit kualitas data sensor secara sistematis;
3. menggunakan statistika deskriptif yang mempertimbangkan distribusi, kelompok, dan struktur waktu;
4. membangun argumen diagnostik dengan stratifikasi, analisis bersyarat, dan fitur *lag*;
5. menghindari interpretasi kausal yang tidak didukung oleh data observasional;

6. membangun dan mengevaluasi model prediksi menggunakan pemisahan data berbasis waktu; dan
7. mengubah hasil analisis menjadi rekomendasi operasional yang proporsional terhadap bukti.

3 Pemahaman Dataset

Dataset memiliki 26 variabel. Variabel utama yang harus dipahami ditunjukkan pada Tabel 1.

Table 1: Kelompok variabel utama dalam dataset.

Kelompok	Variabel	Peran Analitis
Identitas dan waktu	record_id, timestamp, pond_id, day_of_cycle, hour_decimal, time_period	Pengurutan, pengelompokan, dan analisis pola temporal.
Kondisi kolam	pond_volume_m3, stocking_density_kg_m3, biomass_kg	Menjelaskan heterogenitas antar-kolam dan perubahan beban biologis.
Kualitas air	temperature_c, ph, dissolved_oxygen_mg_l, ammonia_mg_l, nitrite_mg_l, turbidity_ntu	Variabel respons dan prediktor utama.
Operasional	feed_kg, aerator_command, aerator_status, aerator_fault, water_exchange_pct	Menilai hubungan tindakan pengelolaan dengan kualitas air.
Lingkungan	rainfall_mm	Menilai pengaruh cuaca dan kemungkinan <i>confounding</i> oleh waktu.
Kualitas dan keluaran	sensor_quality_flag, fish_stress_event, risk_next_3h, dataset_split	Audit data, analisis kejadian, target prediksi, dan pembagian temporal.

Target prediksi didefinisikan sebagai:

$$\text{risk_next_3h} = \begin{cases} 1, & \text{jika dalam enam interval berikutnya terjadi kondisi berisiko,} \\ 0, & \text{jika tidak terjadi kondisi berisiko.} \end{cases}$$

Kondisi berisiko pada generator data adalah oksigen terlarut kurang dari 3,5 mg/L, amonia lebih dari 0,55 mg/L, atau nitrit lebih dari 0,35 mg/L. Enam observasi terakhir setiap kolam tidak memiliki target karena horizon tiga jam tidak lengkap. Ambang ini merupakan asumsi pembelajaran pada data sintetis, bukan standar operasional universal untuk semua sistem budidaya.

4 Tugas Minggu 1: Descriptive dan Diagnostic Analytics

4.1 A. Audit Kualitas Data

Kerjakan seluruh butir berikut sebelum menghitung kesimpulan substantif.

1. Baca CSV dengan `timestamp` sebagai tipe tanggal-waktu. Laporkan jumlah baris, jumlah kolom, periode pengamatan, jumlah kolam, dan interval pencatatan.
2. Periksa keunikan `record_id` dan kombinasi `pond_id`–`timestamp`. Periksa apakah urutan waktu setiap kolam lengkap dan konsisten.

3. Buat tabel tipe data, jumlah nilai hilang, persentase nilai hilang, jumlah nilai unik, minimum, dan maksimum untuk setiap variabel.
4. Ringkas frekuensi setiap nilai `sensor_quality_flag`. Temukan contoh *spike*, *flatline*, *drift*, dan *missing value* pada grafik waktu.
5. Tetapkan aturan analisis untuk nilai sensor bermasalah. Bedakan perlakuan untuk analisis deskriptif, diagnostik, dan prediktif. Jangan mengubah berkas CSV asli.

4.2 B. Descriptive Analytics: Apa yang Terjadi?

1. Hitung mean, median, simpangan baku, minimum, maksimum, kuartil, IQR, dan koefisien variasi untuk seluruh parameter kualitas air. Jelaskan mengapa koefisien variasi tidak selalu tepat ketika mean mendekati nol.
2. Bandingkan statistik kualitas air menurut:
 - kolam;
 - `time_period`;
 - jam pengamatan; dan
 - fase awal, tengah, dan akhir siklus budidaya.
3. Identifikasi parameter yang paling stabil dan paling berfluktuasi. Dukung kesimpulan dengan ukuran statistik dan visualisasi.
4. Hitung frekuensi kondisi berisiko pada waktu pengamatan menggunakan ambang DO, amonia, dan nitrit yang diberikan. Sajikan proporsi menurut kolam dan jam.
5. Analisis distribusi `fish_stress_event`. Kapan dan pada kolam mana kejadian paling sering diamati?

Visualisasi minimum untuk bagian ini adalah histogram atau density plot, boxplot antar-kolam, grafik pola rata-rata per jam, heatmap kolam–jam, dan satu grafik waktu yang memperlihatkan kondisi normal serta ekstrem.

4.3 C. Diagnostic Analytics: Mengapa Terjadi?

Jawab seluruh pertanyaan berikut. Setiap jawaban harus menyertakan ukuran statistik, visualisasi, interpretasi biologis atau operasional, dan keterbatasan inferensi.

1. **Risiko antar-kolam.** Apakah perbedaan risiko dapat dijelaskan oleh biomassa, kepadatan, suhu, atau karakter waktu? Bandingkan besar efek, bukan hanya nilai-*p*.
2. **Aerator dan oksigen terlarut.** Bandingkan DO ketika aerator ON dan OFF secara agregat. Ulangi analisis setelah melakukan stratifikasi berdasarkan jam, kolam, kepadatan, `aerator_command`, dan `aerator_fault`. Apakah kesimpulan berubah? Jelaskan kemungkinan *reverse causality* dan *confounding*.
3. **Gangguan aerator.** Lakukan analisis kejadian dengan jendela tiga jam sebelum dan tiga jam sesudah gangguan. Bandingkan perubahan DO dan risiko dengan periode tanpa gangguan pada jam dan kolam yang sebanding.
4. **Efek tertunda pakan.** Bentuk fitur *lag* 1–12 interval. Pada jeda berapa hubungan pakan dengan amonia, kekeruhan, dan DO paling terlihat? Hindari menggeser data antar-kolam.
5. **Hujan.** Bandingkan tidak hujan, hujan ringan, dan hujan lebat. Lakukan analisis agregat dan analisis dalam strata jam. Jelaskan mengapa hasil keduanya dapat berbeda.

6. **Pertukaran air.** Bandingkan amonia dan nitrit sebelum serta sesudah pertukaran air. Apakah perubahan tersebut konsisten pada semua kolam?

Milestone akhir Minggu 1: kumpulkan memo maksimum dua halaman yang memuat tiga temuan utama, dua masalah kualitas data, satu hipotesis diagnostik yang masih perlu diuji, dan rencana fitur untuk model prediksi.

5 Tugas Minggu 2: Predictive Analytics

5.1 A. Formulasi Prediksi

Bangun model untuk memprediksi `risk_next_3h`. Nyatakan dengan jelas:

- unit prediksi;
- waktu ketika prediksi dibuat;
- fitur yang tersedia pada waktu tersebut;
- tindakan yang mungkin dilakukan setelah peringatan; dan
- konsekuensi *false positive* dan *false negative*.

Ketentuan Metodologis Penting

Gunakan `dataset_split`: TRAIN untuk pelatihan, VALIDATION untuk pemilihan model dan ambang, serta TEST untuk evaluasi akhir satu kali. Dilarang melakukan *random split*. Jangan gunakan `record_id`, `risk_next_3h`, `dataset_split`, atau informasi masa depan sebagai fitur. `species` bersifat konstan. Gunakan `fish_stress_event` hanya untuk analisis deskriptif dan diagnostik agar model berfokus pada early warning berbasis kondisi air dan operasi.

5.2 B. Feature Engineering

Buat sedikitnya empat kelompok fitur berikut:

1. representasi siklus waktu, misalnya pasangan sinus–cosinus untuk jam;
2. nilai *lag* DO, suhu, pH, amonia, atau nitrit;
3. statistik bergerak yang hanya menggunakan waktu saat ini dan masa lalu, misalnya mean, minimum, simpangan baku, atau kemiringan tren;
4. waktu sejak pemberian pakan atau akumulasi pakan masa lalu;
5. interaksi yang memiliki alasan domain, misalnya aerator–fault atau suhu–biomassa.

Seluruh fitur temporal harus dihitung terpisah untuk setiap `pond_id`. Jelaskan baris yang hilang akibat pembentukan *lag* dan kebijakan penanganannya.

5.3 C. Model dan Baseline

Bangun dan bandingkan:

1. **baseline prevalensi**, yaitu selalu memprediksi kelas paling sering;

2. **baseline berbasis aturan** yang ditentukan hanya dari TRAIN;
3. **regresi logistik**; dan
4. sedikitnya satu model berbasis pohon, yaitu decision tree atau random forest.

Transformasi numerik, imputasi, encoding, dan standardisasi harus dipelajari hanya dari TRAIN. Gunakan *pipeline* agar langkah pra-pemrosesan diterapkan konsisten pada VALIDATION dan TEST.

5.4 D. Evaluasi dan Pemilihan Ambang

Laporkan confusion matrix, precision, recall, specificity, F1-score, ROC-AUC, dan PR-AUC. Accuracy hanya digunakan sebagai metrik tambahan. Pilih ambang probabilitas pada VALIDATION dengan mempertimbangkan biaya sederhana:

$$\text{Biaya} = 5 \times FN + 1 \times FP.$$

Setelah model dan ambang dipilih, evaluasi satu kali pada TEST. Bandingkan performa menurut kolam, `time_period`, dan `sensor_quality_flag`. Periksa apakah perubahan prevalensi risiko dari TRAIN ke VALIDATION dan TEST memengaruhi interpretasi hasil.

5.5 E. Interpretasi dan Rekomendasi

1. Jelaskan fitur penting menggunakan koefisien regresi logistik, feature importance, atau metode interpretasi lain yang sesuai.
2. Lakukan analisis sedikitnya 20 kesalahan model yang terdiri atas false positive dan false negative. Cari pola berdasarkan waktu, kolam, aerator, biomassa, dan kualitas sensor.
3. Usulkan dua rekomendasi operasional dan satu rekomendasi pengelolaan sensor.
4. Untuk setiap rekomendasi, nyatakan bukti pendukung, manfaat yang diharapkan, risiko penerapan, dan data tambahan yang diperlukan sebelum diterapkan pada kolam nyata.

6 Luaran dan Format Pengumpulan

Luaran yang Dikumpulkan

1. **Notebook:** `KelompokXX_water_quality.ipynb`. Notebook harus dapat dijalankan dari awal sampai akhir tanpa mengubah CSV sumber.
2. **Laporan PDF:** maksimum 12 halaman di luar lampiran. Struktur minimum: skenario dan pertanyaan, audit data, descriptive analytics, diagnostic analytics, predictive analytics, rekomendasi, keterbatasan, dan simpulan.
3. **Prediksi TEST:** `KelompokXX_test_predictions.csv` dengan kolom `record_id`, `timestamp`, `pond_id`, `y_true`, `y_prob`, dan `y_pred`.
4. **Memo Minggu 1:** PDF maksimum dua halaman.

Setiap tabel dan grafik harus memiliki judul, satuan, keterangan kelompok data, dan interpretasi singkat. Kode yang menghasilkan tabel atau grafik harus tersedia dalam notebook. Tuliskan pembagian kontribusi setiap anggota kelompok pada bagian akhir laporan.

7 Rubrik Penilaian

Komponen	Bobot	Kriteria
Audit dan penyiapan data	10%	Ketepatan struktur data, audit missing/outlier, penanganan flag sensor, dan dokumentasi keputusan pembersihan.
Descriptive analytics	20%	Ketepatan statistik, analisis distribusi, pengelompokan waktu/kolam, kualitas visualisasi, dan kemampuan menemukan pola penting.
Diagnostic analytics	25%	Kualitas stratifikasi, analisis lag dan kejadian, ukuran efek, pengendalian confounding, serta kehati-hatian terhadap klaim kausal.
Predictive analytics	25%	Pencegahan leakage, temporal split, pipeline, baseline, pemilihan model/ambang, metrik yang tepat, dan evaluasi TEST.
Interpretasi dan rekomendasi	10%	Keterkaitan rekomendasi dengan bukti, relevansi operasional, keterbatasan, serta kebutuhan data lanjutan.
Reproducibility dan komunikasi	10%	Notebook dapat dijalankan, kode terstruktur, tabel/grafik terbaca, laporan runtut, dan kontribusi anggota jelas.
Total	100%	

Penggunaan *random split*, kebocoran target, atau penyesuaian model berdasarkan hasil TEST membatasi nilai maksimum komponen predictive analytics menjadi 50% dari bobot komponen tersebut.

8 Pertanyaan:

Jawab secara ringkas pada bagian akhir laporan.

1. Temuan apa yang tidak terlihat jika analisis hanya menggunakan rata-rata seluruh data?
2. Contoh mana yang menunjukkan bahwa korelasi agregat dapat berubah setelah stratifikasi?
3. Keputusan pembersihan data apa yang paling memengaruhi hasil dan mengapa?
4. Mengapa model yang baik pada VALIDATION belum tentu mempunyai performa yang sama pada TEST?
5. Bukti tambahan apa yang diperlukan untuk menyimpulkan bahwa perubahan operasi benar-benar menyebabkan perbaikan kualitas air?

Kode Awal Membaca Data

```
import pandas as pd

df = pd.read_csv(
    "smart_aqua_synthetic_water_quality.csv",
    parse_dates=["timestamp"]
)
```

)

```
df = df.sort_values(["pond_id", "timestamp"]).reset_index(drop=True)
print(df.shape)
print(df.dtypes)
```